

RICE QUALITY IDENTIFICATION FOR INDONESIAN FOOD STANDARDS BASED ON ELECTRONIC NOSE

IDENTIFIKASI KUALITAS BERAS BERDASARKAN STANDAR PANGAN INDONESIA BERBASIS ELECTRONIC NOSE

Muhammad Jauhar Vikri¹, Ifnu Wisma Dwi Prasty², Ucta Pradema Sanjaya³, Mula Agung Barata⁴
^{1,2,3,4}Universitas Nahdlatul Ulama Sunan Giri, Jl. Ahmad Yani No.10, Jambean, Sukorejo, Kec.

Bojonegoro, Kabupaten Bojonegoro, Jawa Timur

¹*vikri@unugiri.ac.id*, ²*ifnuprasty@unugiri.ac.id*, ³*uctapradema@unugiri.ac.id*, ⁴*mula.ab26@gmail.com*.

Abstract - Rice is a staple food in Indonesia, where its quality is regulated by the National Food Standards outlined in National Food Agency Regulation No. 2 of 2023 on Rice Quality and Labeling Requirements. Rice is classified into four grades: premium, medium 1, medium 2, and medium 3. The widespread practice of mislabeling lower-quality rice as a premium through repackaging highlights the critical need for quality control measures. An electronic nose (e-nose) is a reliable device for food quality control. Previous studies have demonstrated its ability to classify rice into two quality grades with 80% accuracy. This study uses exponential data transformation and the Naive Bayes algorithm to enhance the classification accuracy for four rice quality grades according to national standards. The methodology includes signal acquisition, feature extraction using statistical parameters, exponential data transformation, classification, and performance evaluation. The results show that exponential data transformation improves classification accuracy to 97%. This technology can be implemented for automated quality control in milling facilities, storage warehouses, and distribution centres, ensuring consistent rice quality while enhancing supply chain efficiency. The e-nose-based model offers a fast and reliable solution, minimising reliance on human operators.

Keywords - electronic nose, exponential transformation, feature extraction, naive bayes, rice identification.

Beras adalah makanan pokok utama di Indonesia, di mana kualitasnya diatur dalam Standar Pangan Nasional berdasarkan Peraturan Badan Pangan Nasional Republik Indonesia No. 2 Tahun 2023 tentang Persyaratan Mutu dan Label Beras. Beras diklasifikasikan ke dalam empat kelas: premium, medium 1, medium 2, dan medium 3. Pemalsuan beras melalui pengemasan ulang beras berkualitas rendah sebagai beras premium sering terjadi, sehingga pengendalian kualitas beras sangat penting. Electronic nose (e-nose) adalah perangkat andal untuk kontrol kualitas makanan. Penelitian sebelumnya menunjukkan e-nose dapat mengidentifikasi dua kelas mutu beras dengan akurasi 80%. Penelitian ini bertujuan meningkatkan akurasi klasifikasi empat kelas mutu beras sesuai standar nasional menggunakan transformasi data eksponensial dan algoritma Naive Bayes. Metodologi meliputi pengambilan data sinyal, ekstraksi fitur statistik, transformasi eksponensial, klasifikasi, dan evaluasi. Hasil penelitian menunjukkan transformasi eksponensial meningkatkan akurasi klasifikasi hingga 97%. Teknologi ini dapat diterapkan untuk pengendalian kualitas otomatis di pabrik, gudang, dan pusat distribusi, memastikan konsistensi mutu beras, serta mendukung efisiensi rantai pasok. Model berbasis e-nose ini menawarkan solusi cepat dan andal tanpa ketergantungan pada operator manusia.

Kata Kunci - electronic nose, exponential transformation, feature extraction, naive Bayes, identifikasi beras.

I. PENDAHULUAN

Beras merupakan salah satu makanan pokok di dunia. Di Indonesia beras masih menjadi makanan pokok utama sebagian besar masyarakat Indonesia. Di Indonesia mutu beras diatur oleh standar Pangan Nasional Indonesia tertuang pada Peraturan Badan Pangan Nasional Republik Indonesia No 2 Tahun 2023 Tentang Persyaratan Mutu dan Label Beras[1]. Beras diklasifikasikan menjadi 4 kelas, meliputi premium, medium 1, 2 dan 3. Pada pasal II persyaratan mutu menunjukkan bahwa beras memiliki mutu baik paling sedikit memenuhi 3 kriteria berikut meliputi, bebas hama, bebas bau apek, asam dan bau asing lainnya dan persyaratan keamanan. Kriteria bau menjadi poin penting dalam menunjukkan mutu sebuah beras. Beras berkualitas rendah dapat menurunkan harga jual, mengurangi pendapatan petani, dan merugikan konsumen yang mengharapkan produk yang aman dan berkualitas. Oleh karena itu, penelitian ini penting untuk memastikan mutu beras sesuai standar, guna melindungi kesehatan masyarakat sekaligus menjaga stabilitas ekonomi sektor pertanian dan pangan di Indonesia. Electronic nose (e-nose) merupakan alat yang sudah terbukti ampuh digunakan sebagai alat control kualitas dalam makanan. E-nose sudah digunakan sebagai alat kontrol kualitas makanan seperti kue, daging dan kopi[2]–[4] Alat ini digunakan dikarenakan biayanya yang murah, mudah dan cepat penggunaanya serta fleksibel dalam implementasinya[5]. Penelitian ini bertujuan untuk mengklasifikasikan kualitas beras menggunakan elektronik nose menggunakan normalisasi data dengan bantuan metode eksponensial menggunakan algoritma naïve bayes.

Beberapa penelitian elektronik nose dalam mengklasifikasikan kualitas beras. Penelitian kontrol kualitas beras dengan sensor MQ menggunakan jaringan syaraf tiruan dilakukan untuk mengklasifikasikan beras medium dan premium[6]. Pada penelitian lain klasifikasi beras lokal di kabupaten karawang dilakukan dengan hasil bahwa elektronik nose mampu sebagai alat klasifikasi dan sensor MQ layak digunakan sebagai alat pengambilan data[6], [7]. pada penelitian lain penggunaan naïve bayes dalam alat electronic nose pada identifikasi formalin pada tahu menunjukkan hasil akurasi sebesar 60%[8]. Namun pada penelitian sebelumnya belum menggunakan kelas beras sesuai dengan Peraturan Badan Pangan Nasional Republik Indonesia No 2 Tahun 2023 Tentang Persyaratan Mutu dan Label Beras. Maka penelitian ini bertujuan untuk mengklasifikasi 4 jenis beras sesuai dengan peraturan mutu dan label beras dengan proses scaling data menggunakan metode eksponensial dengan menerapkan algoritma naïve bayes.

Kontribusi dari penelitian ini dijelaskan sebagai berikut: (i) penggunaan kelas beras sesuai dengan Peraturan Badan Pangan Nasional Republik Indonesia No 2 Tahun 2023 Tentang Persyaratan Mutu dan Label Beras (ii) penggunaan feature extraction dalam memperkaya fitur yang digunakan klasifikasi dan (iii) pemanfaatan data scaling dalam penyeragaman rentang data sebelum klasifikasi. Sisa dari makalah ini disusun sebagai berikut: Penjelasan rinci tentang metode yang diusulkan dijelaskan di Bagian 2. Hasil dan Pembahasan percobaan dijelaskan di Bagian 3. Selanjutnya, Bagian 4 berisi Kesimpulan dari kegiatan penelitian yang dilakukan. Pada tahap akhir berupa referensi dari penelitian yang dijadikan rujukan.

II. SIGNIFIKANSI STUDI

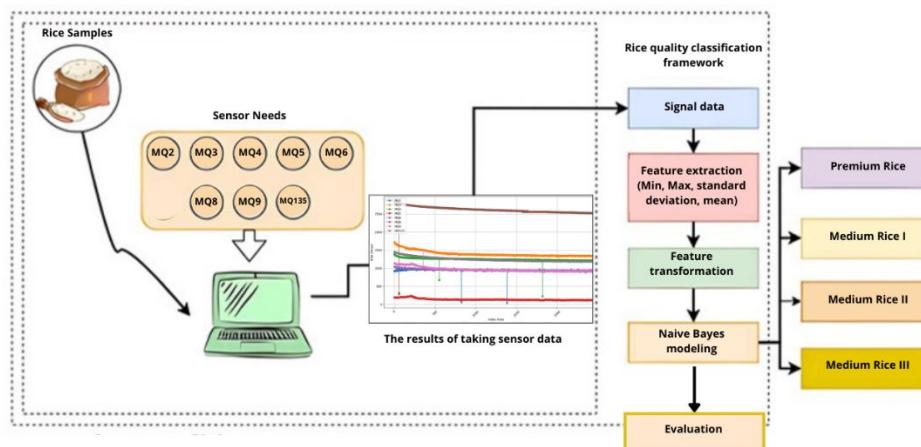
Penelitian ini bertujuan untuk mengoptimalkan kinerja klasifikasi mutu beras dengan menerapkan transformasi eksponensial pada dataset hasil pengukuran menggunakan perangkat electronic nose. Alur metodologi penelitian dapat dilihat pada Gambar 1. Dataset yang digunakan terdiri dari sinyal mentah yang diperoleh dari perangkat e-nose. Sinyal mentah dalam bentuk data digital selanjutnya diproses melalui tahap pra-pemrosesan yang disebut signal de-noising untuk meningkatkan kualitas

data masukan. Setelah proses signal de-noising, langkah berikutnya adalah ekstraksi parameter statistik guna menghasilkan fitur yang merepresentasikan karakteristik data. Fitur-fitur hasil ekstraksi ini mencerminkan distribusi data dari pengukuran yang dilakukan oleh perangkat e-nose.

Transformasi eksponensial dipilih sebagai metode scaling data karena kemampuannya dalam mengurangi dampak noise serta menyelaraskan rentang nilai fitur yang tidak proporsional, terutama pada dataset dengan distribusi yang tidak linier. Transformasi ini membantu meningkatkan sensitivitas model klasifikasi terhadap pola-pola signifikan dalam data. Pada penelitian ini, algoritma Naive Bayes digunakan sebagai metode klasifikasi karena memiliki keunggulan dalam menangani dataset berskala kecil, sederhana dalam implementasi, serta efisien dalam proses komputasi. Selain itu, asumsi independensi antar fitur pada algoritma ini sering kali cukup efektif untuk aplikasi pada data berbasis sinyal seperti hasil pengukuran e-nose.

Beberapa percobaan dilakukan untuk membandingkan hasil klasifikasi dengan dan tanpa transformasi data. Analisis menunjukkan bahwa penerapan transformasi eksponensial dapat meningkatkan keakuratan dan konsistensi hasil klasifikasi. Hasil penelitian ini berpotensi memberikan dampak sosial dan ekonomi yang signifikan. Dari sisi keamanan pangan, teknologi ini dapat membantu mencegah konsumsi beras berkualitas rendah yang mungkin mengandung kontaminasi, meningkatkan kesehatan masyarakat secara keseluruhan. Dari sisi ekonomi, penerapan teknologi e-nose dapat mengurangi biaya produksi melalui pengujian kualitas yang lebih cepat dan efisien dibandingkan metode manual. Produsen dapat memanfaatkan sistem ini untuk mempercepat waktu pengiriman produk ke pasar, mengurangi risiko pengembalian barang akibat ketidaksesuaian mutu, serta meningkatkan reputasi merek dengan menjamin kualitas produk.

Bagi konsumen, manfaatnya meliputi jaminan mutu beras yang dikonsumsi serta perlindungan dari pemalsuan, yang sering kali merugikan secara ekonomi dan kesehatan. Secara lebih luas, teknologi ini juga dapat mendukung upaya pemerintah dalam meningkatkan transparansi rantai pasok pangan, mendorong kepatuhan terhadap standar nasional, dan memperkuat daya saing produk beras Indonesia di pasar internasional.



Gambar 1. Metodologi Penelitian

Dataset

Dataset pada penelitian ini didapatkan dengan pengambilan data menggunakan electronic nose. Perangkat ini dirancang dengan delapan sensor seri MQ yaitu MQ2, MQ3, MQ4, MQ5, MQ6, MQ8, MQ9 dan MQ135. Data yang diambil sebanyak 100 sampel beras setiap kelasnya. Sehingga

keseluruhan total sampel sebanyak 400 sampel yang mencakup 4 kelas beras. Pengambilan data dilakukan selama 60 detik pengambilan setiap sampel. Tabel 1 menunjukkan data yang didapatkan oleh alat *electronic nose*. Total data yang dihasilkan sebanyak 10.000 data sinyal dengan masing-masing 2.500 data sinyal yang dihasilkan pada setiap kelas beras.

TABEL I
DATA SINYAL

MQ2	MQ3	MQ4	MQ5	MQ6	MQ8	MQ9	MQ135	Label
1055	1405	1569	11	1111	2786	820	1509	Premium
1054	1403	1561	15	1114	2784	817	1510	Premium
....
919	1723	1383	192	1045	2844	1139	1449	Medium 1
919	1718	1382	187	1043	2842	1137	1447	Medium 1
....
1294	3058	1535	146	1502	3369	1399	1920	Medium 2
1292	3049	1535	147	1488	3370	1393	1917	Medium 2
....
896	1584	1318	38	999	2919	784	1435	Medium 3
896	1581	1319	35	998	2919	783	1435	Medium 3

Ekstraksi Fitur

Dari data sinyal yang didapatkan dilakukan proses selanjutnya yaitu ekstraksi fitur. Ekstraksi fitur dilakukan dengan menghitung nilai rata-rata, standar deviasi, nilai minimum dan nilai maksimum dari masing-masing kolom sinyal.

Rata-rata

Nilai rata-rata sampel merupakan nilai rata-rata yang dihitung dari penjumlahan total sampel dalam satu kolom dibagi dengan jumlah baris data[9]. Nilai rata-rata dihitung menggunakan persamaan (1) di bawah ini, di mana x_i adalah nilai sampel yang diamati, " μ " adalah nilai rata-rata sampel, dan n adalah jumlah total sampel yang diamati.

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i \quad (1)$$

Standar Deviasi

Simpangan baku diartikan sebagai ukuran seberapa jauh distribusi menyimpang data dari rata-rata[10]. Rumus simpangan baku disajikan pada Persamaan (2), di mana x_i adalah nilai sampel yang diamati, μ adalah rata-rata sampel, dan n adalah jumlah total sampel yang diamati.

$$\sigma = \sqrt{\frac{\sum_{i=1}^n (x_i - \mu)^2}{n-1}} \quad (2)$$

Minimum

Nilai minimum merupakan nilai yang didapatkan dari nilai terkecil pada sebuah data[11]. Pada data sinyal nilai minimum didapatkan pada setiap kolom sinyal MQ yang memiliki nilai terkecil.

Maksimum

Nilai maksimum merupakan nilai terbesar yang didapatkan pada sebuah data[12]. Pada data sinyal nilai maksimum didapatkan pada setiap kolom sinyal MQ yang memiliki nilai terbesar.

TABEL II
HASIL EKSTRAKSI FITUR

Mean MQ2	STD MQ2	Min MQ2	Max MQ2	Label
924,92	3,34	919	932	Medium1
970,92	2,97	962	979	Medium1
913,68	4,92	912	937	Medium1
....
880,44	0,58	880	882	Premium

Proses ekstraksi fitur menghasilkan nilai rata-rata, standar deviasi, minimum dan maksimum. Setiap sensor MQ dihitung nilai rata-rata, standar deviasi, minimum dan maksimum, sehingga setiap satu sensor menghasilkan 4 fitur. Total fitur yang dihasilkan sebanyak 32 fitur pada penelitian ini.

Transformasi Data

Setelah data melalui proses ekstraksi fitur, proses selanjutnya adalah melakukan transformasi data menggunakan eksponensial. Transformasi eksponensial adalah salah satu teknik dalam transformasi data yang digunakan untuk mengubah skala data atau mengatasi masalah seperti skewness (ketidaknormalan distribusi data). Transformasi ini sering digunakan dalam analisis statistik dan machine learning untuk membuat data lebih mendekati distribusi normal atau untuk mengubah sifat hubungan antar variabel[13]. Rumus persamaan transformasi eksponensial disajikan pada persamaan 3 berikut.

$$y = e^x \quad (3)$$

Dengan ketentuan berikut :

y merupakan data hasil transformasi.

x merupakan data asli

e merupakan nilai eksponensial sebesar 2,71828

Naive Bayes

Pemodelan data merupakan proses yang dilakukan setelah data disamakan rentangnya atau ditransformasi. Pemodelan data pada penelitian ini menggunakan algoritma naive bayes. Naive Bayes Classifier adalah metode klasifikasi yang didasarkan pada teorema Bayes. Metode ini menggunakan pendekatan probabilitas dan statistik yang diperkenalkan oleh ilmuwan asal Inggris, Thomas Bayes[14]. Teorema ini memprediksi kemungkinan kejadian di masa depan berdasarkan data atau pengalaman dari masa lalu, sehingga dikenal dengan sebutan Teorema Bayes[15]. Persamaan Naïve bayes disajikan pada persamaan 4.

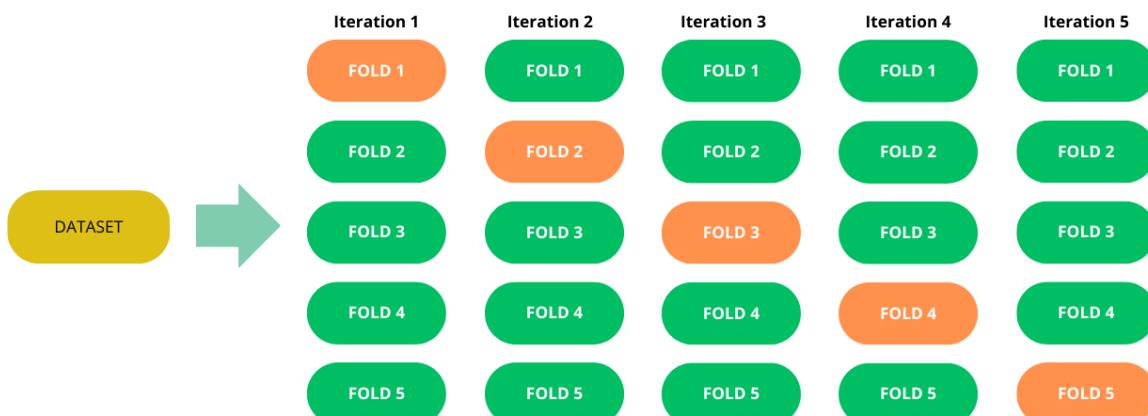
$$P(A|B) \frac{P(B|A)*P(A)}{P(B)} \quad (4)$$

Keterangan:

- $P(A|B)$: Probabilitas hipotesis A menjadi benar berdasarkan data B (posterior probability).
- $P(B|A)$: Probabilitas data B diberikan bahwa hipotesis A benar (likelihood).
- $P(A)$: Probabilitas awal hipotesis A (prior probability).
- $P(B)$: Probabilitas dari data B (evidence).

K-Fold Cross Validation

K-Fold cross validation digunakan dalam evaluasi pada penelitian ini. K-Fold Cross-Validation (CV) adalah metode di mana dataset dibagi menjadi sejumlah K bagian atau fold, di mana setiap fold berfungsi sebagai set pengujian pada beberapa titik waktu[16], [17]. Sebagai contoh, pada skenario validasi silang dengan 5-fold ($K = 5$), data dibagi menjadi 5 fold. Pada iterasi pertama, fold pertama digunakan untuk menguji model, sementara empat fold lainnya digunakan untuk melatih model. Pada iterasi kedua, fold kedua dijadikan set pengujian, dan sisanya berfungsi sebagai set pelatihan. Proses ini diulang hingga semua fold dari 5 fold telah digunakan sebagai set pengujian.



Gambar 2. K-Fold Cross Validation

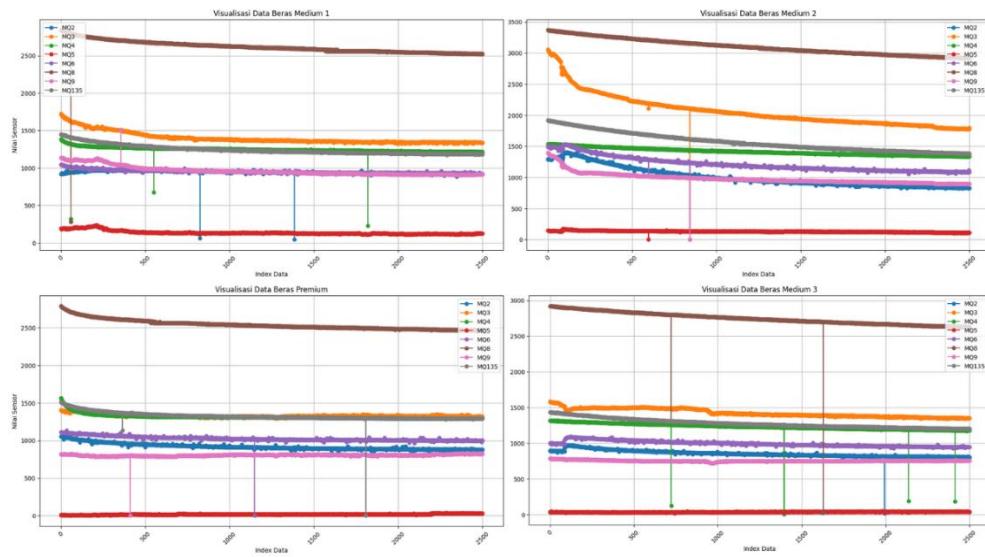
Akurasi yang dihasilkan oleh masing-masing iterasi dihitung rata-ratanya untuk mengetahui rata-rata akurasi model yang sudah dibuat.

III. HASIL DAN PEMBAHASAN

Hasil Pengambilan Data

Pengambilan data menggunakan electronic nose menghasilkan data *raw signal*. Data sinyal didapatkan dengan mengambil nilai analog setiap sensor. Nilai Analog yang didapatkan meliputi

analog MQ2, MQ3, MQ4, MQ5, MQ6, MQ8, MQ9 dan MQ135. Data sinyal yang dihasilkan sebanyak 25 data sinyal setiap sampel pengambilan. Sehingga didapatkan 2500 data sinyal untuk setiap kelas beras, dan 10.000 data untuk dataset. Hasil pengambilan data disajikan pada gambar 3.



Gambar 3. Visualisasi Sinyal

Data yang dihasilkan dapat dilihat dari visualisasi pada gambar 3. Sinyal data dikatakan stabil. Stabilitas sensor dikarenakan proses pemanasan sensor yang dilakukan selama 24 jam setiap sensor sebelum proses pengambilan data dilakukan.

Hasil Ekstraksi Fitur

Setelah data diambil, data sinyal diproses menggunakan Teknik ekstraksi fitur untuk memperkaya fitur pada penelitian ini. Parameter statistika yang digunakan meliputi rata-rata, standar deviasi, nilai minimum dan maksimum. Tabel 3 menunjukkan hasil ekstraksi fitur menggunakan nilai rata-rata pada setiap sensor.

TABEL III
NILAI RATA-RATA SENSOR

Data	MQ2	MQ3	MQ4	MQ5	MQ6	MQ8	MQ9	MQ135	LABEL
1	924,92	1690,44	1362,32	189,84	1036,08	2830,92	1128,28	1438,08	Medium 1
2	970,92	1535,04	1281,68	206,12	985,2	2730,76	1107,6	1343,68	Medium 1
....
101	1292,84	3004,68	1534,96	143,16	1482,72	3363,44	1362,96	1910,28	Medium 2
102	1305,08	2411,56	1503,16	148,76	1422,12	3295,28	1073,52	1808,08	Medium 2
....
201	895,44	1574,04	1316,12	36,92	996,12	2917,84	782,2	1431,2	Medium 3
202	939,24	1495,2	1294,2	32,24	1069,12	2874,52	767,88	1381,52	Medium 3
....
399	974,48	1344,36	1333,88	12,8	1067,96	2622,68	789,88	1379,88	Premium
400	971,4	1342,76	1331,08	13,16	1066,32	2617,76	790,68	1374,84	Premium

Tabel 3 merupakan hasil perhitungan rata-rata dari pengambilan data setiap sensor. Setiap pengambilan data pada setiap sensor MQ2, MQ3, MQ4, MQ5, MQ6, MQ8, MQ9 dan MQ135 dihitung nilai rata-ratanya. Nilai rata-rata masing-masing sensor pada setiap label memiliki nilai yang berbeda-beda. Label medium 1, 2, dan 3 serta premium memiliki nilai yang berbeda-beda setiap sensor. Hal ini menunjukkan fitur menggunakan rata-rata memiliki pengaruh terhadap klasifikasi. Kemudian pada Tabel 4 menunjukkan hasil ekstraksi fitur menggunakan nilai standar deviasi pada setiap sensor.

TABEL IV
NILAI STANDAR DEVIASI SENSOR

Data	MQ2	MQ3	MQ4	MQ5	MQ6	MQ8	MQ9	MQ135	Label
1	3,34	18,12	11,25	3,31	6,73	6,95	7,47	6,46	Medium 1
2	2,97	4,26	1,34	5,68	5,09	2,78	6,14	1,90	Medium 1
....
101	6,12	4,77	1,31	1,34	6,49	1,68	0,93	1,84	Medium 2
102	5,94	5,83	2,01	2,29	6,77	2,92	1,13	3,59	Medium 2
....
201	2,93	4,89	1,42	3,04	4,25	2,01	1,91	2,98	Medium 3
202	4,50	3,90	1,80	1,94	1,87	2,20	0,88	2,98	Medium 3
....
399	1,85	5,46	1,69	2,10	2,38	1,77	1,48	2,08	Premium
400	3,54	3,66	1,49	0,98	2,83	2,68	1,77	2,37	Premium

Tabel 4 merupakan hasil perhitungan standar deviasi dari pengambilan data setiap sensor. Setiap pengambilan data pada setiap sensor MQ2, MQ3, MQ4, MQ5, MQ6, MQ8, MQ9 dan MQ135 dihitung nilai standar deviasinya. Nilai standar deviasi masing-masing sensor pada setiap label memiliki nilai yang berbeda-beda. Label medium 1, 2, dan 3 serta premium memiliki nilai yang berbeda-beda setiap sensor, meskipun memiliki jarak perbedaan yang tidak signifikan. Hal ini menunjukkan fitur menggunakan standar deviasi memiliki pengaruh terhadap klasifikasi. Tabel 5 menunjukkan hasil ekstraksi fitur menggunakan nilai minimum pada setiap sensor.

TABEL V
NILAI MINIMUM SENSOR

Data	MQ2	MQ3	MQ4	MQ5	MQ6	MQ7	MQ8	MQ9	MQ135	Label
1	919	1663	1345	182	1023	2819	1115	1426	919	Medium 1
2	962	1529	1280	193	980	2726	1094	1338	962	Medium 1
....
100	1283	2963	1534	131	1469	3358	1335	1904	1283	Medium 2
101	1266	2406	1498	143	1415	3291	1072	1805	1266	Medium 2
....
200	886	1567	1313	31	981	2914	779	886	1567	Medium 3
201	930	1488	1287	27	1065	2870	767	930	1488	Medium 3
....
399	976	1346	1334	11	1054	2624	786	1377	976	Premium
400	970	1329	1331	5	1063	2618	787	1376	970	Premium

Tabel 5 menunjukkan hasil ekstraksi fitur menggunakan nilai minimum pada setiap sensor. Setiap pengambilan data pada setiap sensor MQ2, MQ3, MQ4, MQ5, MQ6, MQ8, MQ9 dan MQ135 diambil nilai minimumnya. Nilai minimum masing-masing sensor pada setiap label memiliki nilai yang berbeda-beda. Label medium 1, 2, dan 3 serta premium memiliki nilai yang berbeda-beda setiap sensor. Hal ini menunjukkan fitur menggunakan nilai minimum memiliki pengaruh terhadap klasifikasi. Tabel 6 menunjukkan hasil ekstraksi fitur menggunakan nilai maksimum pada setiap sensor.

TABEL VI NILAI MAKSIMUM SENSOR

Data	MQ2	MQ3	MQ4	MQ5	MQ6	MQ7	MQ8	MQ9	MQ135	Label
1	1297	3058	1535	147	1502	3370	1399	1920	1297	Medium 1
2	1319	2416	1507	151	1432	3299	1078	1815	1319	Medium 1
....
100	1297	3058	1535	147	1502	3370	1399	1297	3058	Medium 2

101	1319	2416	1507	151	1432	3299	1078	1319	2416	Medium 2
....
200	899	1584	1319	49	1005	2923	789	1436	899	Medium 3
201	955	1503	1296	38	1072	2879	770	1392	955	Medium 3
....
399	994	1360	1344	16	1097	2637	798	1393	994	Premium
400	881	1325	1296	38	1003	2466	830	1296	881	Premium

Tabel 6 menunjukkan hasil ekstraksi fitur menggunakan nilai maksimum pada setiap sensor. Setiap pengambilan data pada setiap sensor MQ2, MQ3, MQ4, MQ5, MQ6, MQ8, MQ9 dan MQ135 diambil nilai maksimumnya. Nilai maksimum masing-masing sensor pada setiap label memiliki nilai yang berbeda-beda. Label medium 1, 2, dan 3 serta premium memiliki nilai yang berbeda-beda setiap sensor. Hal ini menunjukkan fitur menggunakan nilai maksimum memiliki pengaruh terhadap klasifikasi.

Hasil Transformasi Data

Setelah data dilakukan proses ekstraksi fitur maka fitur yang diperoleh sebanyak 32 fitur. Fitur yang dihasilkan dilakukan proses lanjutan dengan dilakukan proses transformasi data. Transformasi data dilakukan dengan menggunakan metode transformasi eksponensial. Tabel 7 menunjukkan nilai rata-rata sensor setelah dilakukan proses transformasi eksponensial.

TABEL VII
NILAI TRANSFORMASI RATA-RATA SENSOR

Data	MQ2	MQ3	MQ4	MQ5	MQ6	MQ8	MQ9	MQ135
1	1,26	1,25	1,75	2,33	1,21	1,20	1,88	1,00
2	1,35	1,14	1,42	2,52	1,11	1,14	1,82	1,00
3	1,23	1,02	1,19	1,72	1	1,03	1,34	1
4	1,35	1,13	1,42	2,27	1,11	1,14	1,76	1,00
....
400	1,35	1,13	1,41	2,11	1,10	1,13	1,70	1,00

Transformasi data merupakan proses pengubahan atau manipulasi data mentah untuk membuatnya lebih sesuai untuk analisis. Tujuan transformasi data untuk meningkatkan distribusi data, mengurangi efek outlier dan meningkatkan kinerja model, sehingga penggunaan fungsi eksponensial dapat berdampak pada dapat memperbesar perbedaan antar nilai dan memperjelas Pola data dalam kasus sinyal digital. Manfaat yang diharapkan pada proses transformasi ini adalah Model Naive Bayes dapat mengenali perbedaan antar kelas mutu beras dengan lebih baik.

Data hasil transformasi menunjukkan perubahan data dengan skala yang sama pada setiap fitur. Data sebelum transformasi dapat dilihat pada tabel 3 yang menunjukkan setiap fitur memiliki skala yang berbeda terlihat pada fitur MQ 2 dan MQ 5 dengan nilai hasil nilai ratusan. Pada data pertama didapatkan nilai 924,92 pada MQ 2 dan 189,84 pada MQ 5. Sedangkan pada MQ3, MQ4, MQ6, MQ8, MQ9 dan MQ135 memiliki nilai berturut-turut sebesar 1690,44, 1362,32, 1036,08, 2830,92, 1128,28 dan 1438,08. Setelah ditransformasi data memiliki rentang nilai yang seragam pada rentang satuan.

Hasil Klasifikasi Naïve Bayes

Setelah data melalui proses transformasi, selanjutnya dilakukan proses klasifikasi menggunakan metode naive bayes. Klasifikasi dibantu metode K-Fold cross validation dengan nilai k=5. Pada tabel 11 menyajikan hasil akurasi, precision, recall dan f-1 score sistem setiap fold.

TABEL XI
HASIL KLASIFIKASI NAIVE BAYES

Fold	Akurasi	Precision	Recall	f-1 score
1	100%	100%	100%	100%
2	97,5%	97,56%	97,5%	97,5%
3	96,25%	96,44%	96,25%	96,26%
4	95,75%	94,26%	93,75%	93,55%
5	97,5%	97,63%	97,5%	97,5%

Hasil akurasi, precision, recall dan f-1 score pada fold 1 menunjukkan nilai yang sangat tinggi sebesar 100%. dan untuk fold 2 sampai fold 5 menunjukkan nilai diatas 90%, sehingga model yang dihasilkan menunjukkan nilai yang maksimal. Hasil analisis menunjukkan bahwa transformasi eksponensial memberikan peningkatan akurasi yang signifikan ($t = 2,843$, $p < 0.05$) dengan nilai P-value: 0,047. Nilai rata-rata akurasi sistem sebesar 97%, nilai rata-rata precision sistem sebesar 97,18%, nilai rata-rata recall sistem sebesar 97% dan nilai rata-rata f-1 score sistem sebesar 96,96%. Hasil yang didapatkan dalam identifikasi 4 kelas beras yaitu beras premium, medium1, medium 2 dan medium 3 menunjukkan pengidentifikasiannya dengan baik menggunakan alat electronic nose. Untuk menunjukkan hasil secara keseluruhan di sajikan data pada tabel 12 yang menunjukkan hasil akurasi sistem sebelum dan sesudah dilakukan proses transformasi eksponensial data dengan menggunakan 5fold cross validation.

TABEL XII
PERBANDINGAN AKURASI SISTEM

Fold	Naïve Bayes	Naïve Bayes + Tranformasi
1	77,50%	100%
2	97,50%	97,5%
3	72,50%	96,25%
4	91,25%	95,75%
5	72,50%	97,5%

Dari akurasi yang dihasilkan pada k=1 akurasi sistem dengan menggunakan naive bayes menghasilkan akurasi sebesar 77,50% sedangkan setelah dilakukan transformasi eksponensial menjadi 100% hal ini menunjukkan peningkatan akurasi. Pada k=2 akurasi sistem menunjukkan nilai sebesar 97,5% pada pemodelan naive bayes dan didapatkan nilai yang sama sebesar 97,5% setelah dilakukan transformasi eksponensial. Pada k=3 juga mengalami peningkatan akurasi, pada naive bayes didapatkan akurasi 72,5% dan meningkat menjadi 96,25% setelah dilakukan transformasi eksponensial. Terjadi peningkatan pula pada k=4 dan k=5 yang semula pada k=4 memiliki akurasi sistem sebesar 91,25% menjadi 95,75% sedangkan pada k=5 yang semula akurasi sistem sebesar 72,50% menjadi 97,5%. Rata-rata akurasi yang dihasilkan pada penelitian ini dengan menggunakan transformasi eksponensial sebesar 97% sedangkan tanpa proses transformasi eksponensial akurasi sistem hanya sebesar 82%. Hal ini menunjukkan bahwa transformasi eksponensial dapat meningkatkan akurasi sistem yang dibuat menggunakan naive bayes. Teknologi ini dapat diterapkan untuk pengendalian kualitas otomatis di pabrik, gudang, dan pusat distribusi, memastikan konsistensi mutu beras, serta mendukung efisiensi rantai pasok. Model berbasis e-nose ini menawarkan solusi cepat dan andal tanpa ketergantungan pada operator manusia.

IV. KESIMPULAN

Penelitian ini bertujuan untuk meningkatkan akurasi klasifikasi mutu beras ke dalam empat kelas, yaitu premium, medium 1, medium 2, dan medium 3, dengan menggunakan transformasi eksponensial pada data sinyal yang dihasilkan oleh electronic nose dan algoritma Naive Bayes. Hasil penelitian menunjukkan bahwa tujuan tersebut telah tercapai. Transformasi eksponensial terbukti mampu meningkatkan akurasi klasifikasi hingga 97%, dibandingkan dengan akurasi 82% tanpa transformasi. Hal ini mengindikasikan bahwa metode transformasi eksponensial efektif dalam memperbaiki kualitas data sinyal untuk proses klasifikasi.

Proses ekstraksi fitur yang menghasilkan 32 fitur baru juga berperan penting dalam memperkaya informasi dari sinyal mentah, sehingga mendukung keberhasilan klasifikasi. Hasil ini mendukung aplikasi praktis electronic nose dalam pengendalian mutu beras secara cepat, akurat, dan efisien. Hasil analisis menunjukkan bahwa transformasi eksponensial memberikan peningkatan akurasi yang signifikan ($t = 2,843$, $p < 0.05$) dengan nilai P-value: 0,047, dengan rata-rata akurasi meningkat dari 82% menjadi 97%. Hal ini mendukung klaim bahwa ada perbedaan yang signifikan secara statistik antara akurasi sistem dengan dan tanpa transformasi eksponensial. Untuk penelitian selanjutnya, pengolahan outlier pada data sinyal diusulkan guna lebih meningkatkan stabilitas dan akurasi sistem. Langkah ini diharapkan semakin memperkuat relevansi electronic nose sebagai solusi inovatif dalam pengujian mutu beras yang sesuai dengan standar nasional.

REFERENSI

- [1] B. RI, "Peraturan BPOM No.2 Tahun 2023 Persyaratan Mutu dan Label Beras," *Peratur. Menteri Kesehat. Republik Indones. Nomor 4 Tahun 2018*, vol. 151, no. 2, pp. 10–17, 2023.
- [2] M. S. H. Ardani *et al.*, "Electronic Nose Signals for Analysing Similarity of Male and Female Axillary Odour to Food Material Aroma," *Int. J. Intell. Eng. Syst.*, vol. 15, no. 5, pp. 601–611, 2022, doi: 10.22266/ijies2022.1031.52.
- [3] D. R. Wijaya, R. Sarno, E. Zulaika, and F. Afianti, "Electronic nose homogeneous data sets for beef quality classification and microbial population prediction," *BMC Res. Notes*, vol. 15, no. 1, pp. 9–11, 2022, doi: 10.1186/s13104-022-06126-9.
- [4] S. Wakhid, R. Sarno, S. I. Sabilla, and D. B. Maghfira, "Detection and classification of indonesian civet and non-civet coffee based on statistical analysis comparison using E-Nose," *Int. J. Intell. Eng. Syst.*, vol. 13, no. 4, pp. 56–65, 2020, doi: 10.22266/IJIES2020.0831.06.
- [5] S. I. S. Malikhah Malikhah, Riyanto Sarno, "Ensemble Learning for Optimizing Classification of Pork Adulteration in Beef Based on Electronic Nose Dataset," *J. Palliat. Care*, vol. 14, no. 11, pp. 1–3, 2021, [Online]. Available: <https://journals.sagepub.com/description/PAL>
- [6] D. A. Raihan, D. Syauqi, and B. H. Prasetyo, "Klasifikasi Kualitas Beras berdasarkan Nilai Data Larik Sensor Gas MQ menggunakan metode Jaringan Syaraf Tiruan berbasis Arduino," *J. Pengemb. Teknol. Inf. dan ilmu Komput.*, vol. 6, no. 6, p. 8, 2022.
- [7] N. Fauji, Ibrahim, E. Widianto, V. Efeline, and R. Hanifi, "Klasifikasi Beras Lokal Di Karawang Berbasis Electronic Nose Menggunakan Larik Sensor Mq," *Encycl. Neurosci.*, vol. 2, no. 1, pp. 871–877, 2019.
- [8] F. T. Admojo and S. R. Jabir, "Analisis performa metode Naïve Bayesh Classifier pada Electronic Nose dalam identifikasi formalin pada tahu," *Indones. J. Data Sci.*, vol. 4, no. 1, pp. 1–16, 2023, doi: 10.56705/ijodas.v4i1.67.
- [9] A. A. N. Risal, N. I. Yusuf, A. B. Kaswar, and F. Adiba, "Penerapan data mining dalam mengklasifikasikan tingkat kasus Covid-19 di Sulawesi Selatan menggunakan Algoritma Naive

- Bayes,” *Indones. J. Fundam. Sci.*, vol. 7, no. 1, pp. 18–28, 2021.
- [10] E. Darnila, M. Maryana, and M. Azmi, “Aplikasi Klasifikasi Status Gizi Balita Menggunakan Metode Naïve Bayes Berbasis Android,” *METHOMIKA J. Manaj. Inform. dan Komputerisasi Akunt.*, vol. 5, no. 2, pp. 135–141, 2021, doi: 10.46880/jmika.vol5no2.pp135-141.
- [11] M. Anugrahayu and U. Azmi, “Stock Portfolio Optimization Using Mean-Variance and Mean Absolute Deviation Model Based On K-Medoids Clustering by Dynamic Time Warping,” *J. Mat. Stat. dan Komputasi*, vol. 20, no. 1, pp. 164–183, 2023, doi: 10.20956/j.v20i1.27755.
- [12] D. Prasetyawan and R. Gatra, “Algoritma K-Nearest Neighbor untuk Memprediksi Prestasi Mahasiswa Berdasarkan Latar Belakang Pendidikan dan Ekonomi,” *JISKA (Jurnal Inform. Sunan Kalijaga)*, vol. 7, no. 1, pp. 56–67, 2022, doi: 10.14421/jiska.2022.7.1.56-67.
- [13] Muhammad Jauhar Vikri and R. Rohmah, “Penerapan Fungsi Exponential Pada Pembobotan Fungsi Jarak Euclidean Algoritma K-Nearest Neighbor,” *Gener. J.*, vol. 6, no. 2, pp. 57–64, 2022, doi: 10.29407/gj.v6i2.18070.
- [14] N. G. A. Dasriani, S. Hadi, and M. Syahrir, “Intelligent System for Internet of Things-Based Building Fire Safety with Naive Bayes Algorithm,” *MATRIK J. Manajemen, Tek. Inform. dan Rekayasa Komput.*, vol. 23, no. 1, pp. 229–242, 2023, doi: 10.30812/matrik.v23i1.3581.
- [15] M. Siswanto, Andriyansyah, “Penerapan Algoritma Topsis untuk Perekutan Karyawan Divisi HRD pada CV. Semito Mandiri,” *Pros. Semin. Nasional(Sisfotek)*, vol. 3, no. 1, pp. 44–52, 2019.
- [16] H. Hafid, “Penerapan K-Fold Cross Validation untuk Menganalisis Kinerja Algoritma K-Nearest Neighbor pada Data Kasus Covid-19 di Indonesia,” *J. Math.*, vol. 6, no. 2, pp. 161–168, 2023, [Online]. Available: <http://www.ojs.unm.ac.id/jmathcos>
- [17] A. N. Ikhsan, P. Subarkah, and R. S. Alifian, “Komparasi Algoritme K-NN, Naïve Bayes, dan Cart untuk Memprediksi Penerima Beasiswa,” *JST (Jurnal Sains dan Teknol.)*, vol. 12, no. 2, pp. 309–316, 2023, doi: 10.23887/jstundiksha.v12i2.51745.

UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih kepada Kementerian Pendidikan, Kebudayaan, Riset, dan Teknologi (Kemendikbudristek) atas dukungan melalui Program Penelitian Dosen Pemula. Ucapan terima kasih juga disampaikan kepada Universitas Nahdlatul Ulama Sunan Giri, khususnya Lembaga Penelitian dan Pengabdian Masyarakat (LPPM), yang telah memberikan dukungan dan fasilitas selama pelaksanaan penelitian ini.